Badr TADJER | Naoufal ARRADI | Leo TRAN LS1-M1-APP

Session 3 – TP Machine Learning



Train accuracy indique que 80% de nos trains sont corrects et Test accuracy indique que 77% de nos tests sont corrects.

En conclusion, les valeurs sont assez proches, par conséquent nous ne sommes pas sur un cas d'overfitting.

Let's print the model's parameters

```
print(coeff)
              Feature Coefficient Estimate
                            -1.158693
-2.708761
-0.040634
               Pclass
                Sex
Age
                SibSp
                             -0.334012
                Parch
                              0.071939
                Fare
                             -0.000570
             Embarked
                              -0.223307
          7 Intercept
                              5.391545
```

We now need to predict class labels for the test set. We will also generate the class probabilities

Nous avons ici la probabilité de mort à gauche et la probabilité de survie à droite. Afin de choisir si le résultat sera Mort ou Survie, la machine sélectionne la probabilité la plus haute entre les deux. As you can see, the classifier outputs two probabilities for each row. It's predicting a 1 (Survived) any time the probability in the second column is greater than 0.5. Let's visualize it all together.

Out[20]:

	Survived_original	Survived_predicted	Survived_proba	Comparison
Passengerld				
863	1	1	0.860689	True
224	0	0	0.084543	True
85	1	1	0.873336	True
681	0	1	0.634082	False
536	1	1	0.922157	True

Confusion matrix

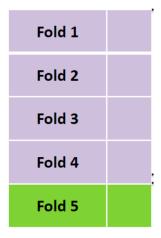
[[129 24] [37 78]] precision recall f1-score support	<pre>print (metrics.confusion_matrix(y_test, y_pred)) print (metrics.classification_report(y_test, y_pred))</pre>						
1 0.76 0.68 0.72 115 accuracy 0.77 268		precision	recall	f1-score	support		
1 0.76 0.68 0.72 115 accuracy 0.77 268	0	0.78	0.84	0.81	153		
	1						
	accuracy						
macro avg							

Notre matrice de confusion est la suivante :

		Predicted class		
		Negative	Positive	
Actual class	Negative	129	24	
Actual class	Positive	37	78	

K-Fold Cross Validation Entrée [24]: # import cross_validation from: http://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_s # your code here from sklearn.model_selection import cross_val_score clf = LogisticRegression(random_state = 1) scores = cross_val_score(clf, titanic[predictors], titanic["Survived"], scoring = 'accuracy', cv = 5) ## see model print(scores) # Take the mean of the scores (because we have one for each fold) print(scores.mean()) [0.7877095 0.78651685 0.78089888 0.76966292 0.82022472] 0.7890025735986442 When you are improving a model, you want to make sur that you are really doing it and not just being lucky. This is why it's good to work with cross validation instead of one train/test split.

Ici nous avons divisé notre modèle en 5 Folds et nous avons réitéré l'opération 5 fois.



Entrée []:

Nous avons obtenu les précisions suivantes :

 $[0.7877095,\ 0.78651685,\ 0.78089888,\ 0.76966292,\ 0.82022472]$

Et la moyenne des ces précisions est de **0.7890025735986442**, donc 78 % d'exactitude en moyenne.